LEMBAR KERJA PERTEMUAN KE 3

Capstone Idea Discovery Canvas

Gunakan lembar kerja ini untuk mengubah temuan dari minimal tiga paper menjadi satu ide capstone yang memiliki masalah nyata, bukti gap, dan bentuk demo yang realistis.

A Informasi Kelompok

Nama kelompok	Kelompok 14
Anggota dan NIM	Dwi Nabila Dhiya Ulhaq – 233510384 Tasya Mulyani - 233510145
Bidang atau topik	Rekayasa perangkat lunak dan kecerdasan buatan: generator soal ujian teori berkendara otomatis (LLM + RAG) dari dokumen peraturan keselamatan, pada sistem ujian IMKP (PT Pertamina Patra Niaga RU II Dumai)

Target Hasil Pertemuan

- ☐ Tiga paper relevan telah dibuka dan diperiksa pada sumber aslinya.
- ☐ Satu research gap atau opportunity telah disintesis dari beberapa paper.
- ☐ Satu problem statement dan target pengguna telah ditetapkan.
- ☐ Satu ide capstone dengan demo minimum dan ukuran keberhasilan telah dirumuskan.

Petunjuk Pengisian

1. Gunakan Google Scholar Labs untuk eksplorasi, lalu verifikasi setiap temuan pada paper asli.
2. Tuliskan bagian atau halaman paper yang menjadi bukti agar gap dapat ditelusuri.
3. Pilih satu gap yang penting bagi pengguna dan mungkin dikerjakan selama periode capstone.
4. Fokus pada demo minimum. Teknologi dapat disempurnakan setelah ide dinyatakan layak.

B Bukti dari Literatur

Isi berdasarkan isi paper, bukan hanya ringkasan dari Scholar Labs. Pada kolom sumber bukti, tuliskan halaman, bagian, tabel, atau gambar yang mendukung temuan.

No	Identitas paper	Masalah dan konteks	Metode atau solusi	Hasil utama	Keterbatasan atau peluang	Sumber bukti
1	Hamidi, C., Badiy, M., Gaou, S., Amounas, F., Azrour, M., Tribak, H., Alnajim, A. M., & Alabdulatif, A. **Enhancing Automated Exam Creation with Retrieval-Augmented Generation for Scalable Educational Assessment.** 2025. Journal of Advances in Information Technology, 16(10), 1430–1441. DOI: 10.12720/jait.16.10.1430-1441	LLM tanpa retrieval dapat berhalusinasi dan kurang selaras dengan kurikulum, sedangkan menyusun soal bermutu memakan waktu pengajar. Konteks: soal ujian SQL berbahasa Prancis.	Pipeline RAG: 102 PDF diekstrak, di-chunk, di-embed (all-MPNet-base-v2), diindeks FAISS; retrieval k=25 lalu re-ranking dan pembersihan; LLaMA 3.2 (Ollama) membuat soal pilihan ganda JSON (4 opsi, kunci, penjelasan); ditinjau pakar; antarmuka web Next.js.	Precision@5 retrieval 85%; re-ranking menambah 8–12%; tingkat kesulitan sesuai sekitar 85%; kepatuhan skema JSON sekitar 90%; 20–45 detik per soal. Klaim penulis: waktu menyusun kuis turun dari sekitar 21 ke 6 menit (pilot 16 mahasiswa dan 4 pengajar).	Domain SQL dan korpus PDF publik; pilot kecil; sekitar 10% keluaran melanggar skema; latensi tinggi; metrik akurasi faktual dan benchmark pembanding masih direncanakan. Peluang: korpus peraturan lokal, evaluasi akurasi terukur, integrasi alur ujian.	Abstrak; Bagian III.A–B dan Gambar 1; Bagian IV.B–D; Bagian V.B.3; Bagian V.D (keterbatasan)
2	Arif, T., Asthana, S., & Collins-Thompson, K. **Generation and Assessment of Multiple-Choice Questions from Video Transcripts using Large Language Models.** 2024. Proc. L@S '24, hlm. 1–7. DOI: 10.1145/3657604.3664714	Soal pilihan ganda buatan LLM perlu dinilai kualitasnya sebelum dipakai peserta. Konteks: transkrip kuliah video pada program daring ilmu data.	GPT-3.5/GPT-4 membuat 15 soal per segmen transkrip. Kualitas dinilai 2 anotator manusia (100 soal), cek berbasis aturan (n=1850), dan penilaian LLM (n=100) dengan 19 kriteria cacat penulisan soal (Item-Writing Flaw).	Manusia: 51–65% soal tanpa cacat; penilaian otomatis hanya 15–25% lolos semua kriteria. Rata-rata sekitar 1,6 cacat per soal. Pengecoh tidak masuk akal adalah cacat tersering (57% soal punya minimal satu); 17% kurang konteks.	Satu domain (STEM, bahasa Inggris) dan model komersial; soal yang bergantung konteks visual tidak dapat dijawab. Peluang: koreksi hibrida LLM + pakar, serta pemeriksaan kualitas otomatis sebelum review.	Abstrak; Bagian 4.1 dan Tabel 1; Bagian 4.2 dan Tabel 2–5; Bagian 5; Tabel 6 (daftar cacat)
3	Lee, J., Smith, D., Woodhead, S., & Lan, A. **Math Multiple Choice Question Generation via Human-Large Language Model Collaboration.** 2024. Proc. 17th Int. Conf. on Educational Data Mining (EDM), hlm. 941–946. DOI: 10.5281/zenodo.12730005	Soal pilihan ganda matematika bermutu padat karya; LLM sulit mengantisipasi kesalahan umum sehingga pengecoh kurang tepat. Konteks: asesmen matematika sekolah.	Prototipe HEDGE: LLM membuat soal, kunci, penjelasan, lalu pengecoh, miskonsepsi, dan umpan balik; pendidik menilai dan mengedit tiap langkah. Pilot dengan 4 guru, GPT-4, 5 topik.	14 dari 20 paket soal+kunci+penjelasan dinilai valid (70%), tetapi hanya 37% paket miskonsepsi–pengecoh–umpan balik yang valid. Rating guru: 4 untuk soal, 2,5 untuk pengecoh (skala 5).	Pilot kecil (4 peserta, 5 topik, hanya matematika dan GPT-4). Penulis menyarankan kolaborasi manusia–LLM diperluas ke domain lain. Peluang: alur review manusia pada domain berisiko tinggi.	Abstrak; Bagian 1.1; Bagian 4.1–4.3; Tabel 4; Bagian 5

Identitas paper minimum: judul, penulis, tahun, serta DOI atau tautan.

C Sintesis Temuan dan Gap

1 Pola yang ditemukan dari beberapa paper *Tuliskan persamaan, perbedaan, atau kecenderungan yang berulang.*

Persamaan: ketiga paper memakai LLM untuk membuat soal pilihan ganda dan sepakat bahwa hasilnya belum dapat dipakai begitu saja. Paper 2 menemukan hanya 15–25% soal yang lolos semua pemeriksaan otomatis (51–65% menurut manusia), dan Paper 3 hanya mendapat 37% paket pengecoh yang valid, sehingga pemeriksaan kualitas dan review manusia diperlukan.

Perbedaan: hanya Paper 1 yang menambatkan pembuatan soal pada dokumen sumber (RAG) dengan model lokal (Ollama + LLaMA 3.2). Pendekatan ini ditujukan untuk menekan halusinasi dan menjaga keselarasan materi, tetapi paper itu sendiri menyebut akurasi faktual dan pembanding masih direncanakan.

Kecenderungan: semua studi memakai materi akademik (SQL, ilmu data, matematika). Belum ada yang menerapkannya pada dokumen peraturan keselamatan untuk ujian izin mengemudi di kawasan industri, dalam bahasa Indonesia, dan terhubung ke alur ujian operasional.

2 Gap atau opportunity yang dipilih *Pilih satu yang paling penting dan realistis.*

- ☐ Keterbatasan data atau konteks
- ☐ Belum diuji dengan pengguna
- ☒ Belum diterapkan pada domain atau lokasi tertentu
- ☐ Integrasi sistem belum tersedia
- ☐ Belum ada implementasi atau prototipe
- ☐ Solusi sulit digunakan
- ☐ Performa atau metode masih dapat ditingkatkan
- ☐ Lainnya

3 Pernyataan gap berbasis bukti *Gunakan format: Paper A menunjukkan..., sedangkan Paper B/C menunjukkan....*

Paper 1 menunjukkan bahwa soal ujian dapat dibangkitkan dari dokumen sumber dengan RAG dan LLM lokal untuk menekan halusinasi, sedangkan Paper 2 dan Paper 3 menunjukkan bahwa soal buatan LLM tetap memuat cacat (pengecoh tidak masuk akal pada 57% soal di Paper 2; hanya 37% paket pengecoh valid di Paper 3) sehingga perlu pemeriksaan dan review manusia.

Ketiganya diuji pada materi pendidikan akademik, belum pada dokumen peraturan keselamatan untuk ujian teori berkendara di kawasan kilang yang soalnya harus selaras dengan aturan perusahaan.

D Masalah Nyata dan Target Pengguna

Target pengguna

Lima entitas pengguna sistem:
1) Vendor: mendaftarkan peserta dan mengajukan akses ke refinery unit.
2) Refinery Unit: unit kilang yang menjadi lingkup data (plan ujian, bank soal, dokumen peraturan, template badge).
3) Checkpoint: menghasilkan dan mereview soal, menerbitkan OTP, memverifikasi hasil.
4) Petugas Safety: memberi persetujuan akhir dan dapat memvalidasi isi soal terhadap peraturan.
5) Peserta: pekerja vendor/kontraktor yang mengerjakan ujian teori sebelum mengemudi di kawasan kilang.

Situasi atau konteks pengguna

Setiap personel yang mengemudi di kawasan kilang wajib memiliki IMKP, yang hanya terbit setelah lulus ujian teori berkendara. Ujian memakai beberapa plan (per golongan SIM A/BI/BII dan per refinery unit), dengan materi rambu, aturan berkendara, defensive driving, HSSE, dan kondisi darurat.

Tujuannya agar pengemudi kilang benar-benar terbukti memahami aturan keselamatan sebelum diizinkan mengemudi. Karena itu isi soal harus selaras dengan peraturan keselamatan yang berlaku, bukan sekadar variatif.

Problem statement *[Pengguna] mengalami [masalah] ketika [situasi], yang menyebabkan [dampak].*

Petugas Checkpoint dan Safety di refinery unit mengalami kesulitan menyediakan bank soal ujian teori berkendara yang beragam dan terbukti sesuai peraturan keselamatan ketika harus menguji peserta vendor pada berbagai plan ujian, yang menyebabkan soal terbatas dan berulang, isi soal AI berisiko tidak selaras dengan peraturan, dan kelulusan peserta belum dapat dijadikan jaminan bahwa pengemudi kilang paham aturan yang berlaku.

Bukti bahwa masalah ini nyata *Boleh berasal dari literatur, observasi, data, atau pengalaman calon pengguna.*

Dari laporan KP (3.5.1 butir b): bank soal disusun penuh secara manual oleh tim Checkpoint, memerlukan waktu dan tenaga, sehingga variasi soal terbatas dan berulang. Laporan juga menekankan perlunya tinjauan manusia atas soal AI pada konteks keselamatan (3.5.3 butir d; 4.1 butir 3) dan menyarankan evaluasi otomatis kualitas soal (4.2 butir 3).

Dari kode sistem: generator AI saat ini membuat soal dari kategori topik (rambu, aturan berkendara, defensive driving, HSSE, kondisi darurat), tidak dari dokumen peraturan, sehingga tidak ada tautan ke sumber aturan yang dapat diperiksa reviewer.

Dari literatur: Paper 1 mencatat risiko halusinasi LLM tanpa retrieval; Paper 2 dan 3 menunjukkan soal AI memuat cacat dan perlu review.

Perlu dilengkapi: contoh dokumen peraturan yang dipakai di RU II dan keterangan petugas Checkpoint/Safety (jumlah soal, frekuensi pembaruan, kasus soal tidak sesuai aturan). Belum terverifikasi di lapangan.

E Ide Capstone

Judul sementara *Pengembangan [produk atau sistem] menggunakan [pendekatan] untuk [pengguna atau tujuan].*

Pengembangan Sistem Generator Soal Ujian Teori Berkendaraan Otomatis Berbasis Large Language Model dan Retrieval-Augmented Generation (RAG) dari Dokumen Peraturan Keselamatan

Solusi yang diusulkan *Jelaskan hubungan langsung antara solusi dan masalah pengguna.*

Sistem IMKP (ASP.NET Core, SQL Server, Ollama) dari masa KP diperluas dengan modul RAG. Dokumen peraturan keselamatan per refinery unit diunggah, diekstrak, dipecah menjadi potongan teks, diberi embedding, dan disimpan sebagai indeks. Saat Checkpoint meminta soal untuk suatu plan, sistem mengambil potongan peraturan yang relevan dan LLM lokal membuat soal pilihan ganda, kunci, penjelasan, beserta sitasi sumber (dokumen dan halaman/pasal).

Soal masuk antrean Pending setelah pemeriksaan otomatis (format A–D, duplikat, kecocokan kunci dengan konteks). Checkpoint (dan Petugas Safety bila perlu) meninjau dengan melihat sumbernya, lalu soal yang disetujui masuk Bank Soal dan dipakai pada ujian peserta.

Hubungan dengan masalah: RAG membuat soal bersumber dari aturan yang berlaku dan dapat ditelusuri, sedangkan review manusia menjaga mutu pada konteks keselamatan.

Alur solusi

Input	Proses utama	Output	Pengguna
Dokumen peraturan keselamatan (PDF) per refinery unit Parameter: plan/jenis SIM, topik, jumlah soal	Ekstraksi teks, chunking, embedding, indeks Retrieval konteks relevan (top-k) LLM lokal membuat soal + kunci + penjelasan + sitasi Pemeriksaan otomatis dan review manusia	Soal Pending dengan sitasi sumber Setelah disetujui: masuk Bank Soal Sesi ujian peserta berisi soal acak unik; skor dan status lulus	Checkpoint (generate dan review) Petugas Safety (validasi dan approval) Peserta (ujian) Vendor dan Refinery Unit (lingkup data)

F Demo Minimum dan Batas Scope

Pernyataan demo minimum *Pada akhir capstone, pengguna dapat..., sistem memproses..., kemudian menghasilkan....*

Pada akhir capstone, Checkpoint dapat mengunggah dokumen peraturan keselamatan suatu refinery unit, sistem mengindeksnya dan membangkitkan soal pilihan ganda untuk satu plan ujian beserta sitasi sumbernya, Checkpoint mereview dan menyetujui soal tersebut ke Bank Soal, kemudian peserta mengerjakan ujian dari soal itu dan sistem menghasilkan skor serta status lulus untuk diteruskan ke verifikasi dan approval.

Tiga fungsi wajib dalam demo

1	Manajemen dokumen peraturan: unggah PDF per refinery unit, ekstraksi dan chunking, embedding, dan penyimpanan indeks.
2	Generate soal berbasis RAG: retrieval konteks, LLM lokal membuat soal A–D dengan kunci, penjelasan, dan sitasi sumber, lalu pemeriksaan otomatis.
3	Review dan ujian: setujui, edit, atau tolak soal dengan melihat sumbernya; soal disetujui masuk Bank Soal dan dipakai pada ujian peserta (alur OTP, skor, dan status lulus).

Tidak termasuk dalam scope capstone *Tuliskan fitur atau pekerjaan yang sengaja ditunda.*

Ujian praktik mengemudi (sistem ini hanya menguji teori); fine-tuning model; aplikasi mobile; pengawasan ujian berbasis kamera; analisis butir soal skala besar; integrasi SSO/HR perusahaan; dokumen berbentuk pindaian (scan) yang butuh OCR; soal bergambar hasil RAG dari dokumen; deployment ke server produksi perusahaan.

G Kelayakan Awal

Pertanyaan pemeriksaan	Jawaban kelompok
Apakah data dapat diperoleh? Dari mana?	Sebagian. Dokumen peraturan keselamatan RU II perlu diminta ke pembimbing lapangan/unit HSSE dan izin pemakaiannya (isi mungkin internal atau rahasia) belum dipastikan. Cadangan: peraturan publik (misalnya UU No. 22 Tahun 2009 tentang LLAJ dan pedoman keselamatan yang dapat dipublikasikan) dan dokumen contoh buatan.
Apakah teknologi dapat dipelajari dalam waktu yang tersedia?	Ya. ASP.NET Core, EF Core, SQL Server, dan Ollama sudah dikuasai selama KP. Yang baru dipelajari: chunking, embedding, penyimpanan dan pencarian vektor, serta prompt berbasis konteks. Paper 1 membuktikan pipeline serupa (Ollama + LLaMA 3.2 + FAISS) layak dibangun pada skala proyek akademik.
Apakah demo dapat dibuat tanpa menunggu pihak eksternal?	Ya untuk fungsi inti, karena model dan indeks berjalan lokal tanpa API berbayar. Pihak luar hanya dibutuhkan untuk menyediakan dokumen dan menilai isi soal (Checkpoint/Safety atau pembimbing).
Apa risiko terbesar proyek ini?	(1) Dokumen peraturan asli tidak boleh diakses atau dipakai; (2) ekstraksi PDF berantakan (tabel, daftar, pindaian) sehingga retrieval kurang tepat; (3) kualitas model 7B lokal dalam bahasa Indonesia dan kecepatan generate pada perangkat demo; (4) soal tetap bisa keliru walau ada konteks, seperti temuan Paper 2 dan 3.
Apa rencana alternatif jika data atau teknologi tidak tersedia?	Dokumen publik atau buatan sebagai korpus; model embedding/LLM lain bila hasil kurang; generator lama (tanpa RAG) tetap ada sebagai pembanding dan cadangan; evaluasi difokuskan pada kualitas retrieval, sitasi, dan alur review.

H Kontribusi atau Pembeda

Pernyataan pembeda *Penelitian atau sistem sebelumnya berfokus pada..., sedangkan capstone kami akan....*

Penelitian sebelumnya berfokus pada pembangkitan soal pilihan ganda dari materi akademik (SQL, ilmu data, matematika), dengan pembuktian akurasi yang masih terbatas, sedangkan capstone kami akan mengimplementasikan generator soal berbasis RAG dan LLM lokal dari dokumen peraturan keselamatan berbahasa Indonesia, lengkap dengan sitasi sumber, pemeriksaan otomatis, review manusia, dan terhubung langsung ke alur ujian IMKP di kawasan kilang, serta mengevaluasinya terhadap pembangkit tanpa RAG.

- ☒ Implementasi menjadi aplikasi atau prototipe
- ☒ Integrasi beberapa metode atau sistem
- ☒ Evaluasi dengan pengguna nyata
- ☐ Peningkatan metode atau performa
- ☒ Penerapan pada konteks atau pengguna berbeda
- ☐ Peningkatan pengalaman pengguna
- ☒ Penggunaan dataset lokal
- ☐ Lainnya

I Ukuran Keberhasilan

Tentukan indikator yang dapat diuji pada demo, bukan hanya pernyataan bahwa sistem sudah dibuat.

No	Indikator keberhasilan	Cara pengujian atau target
1	Kesesuaian soal dengan dokumen peraturan.	Dari minimal 40 soal RAG dan 40 soal tanpa RAG (generator lama) pada topik yang sama, reviewer menilai apakah kunci dan pernyataan soal didukung dokumen sumber. Target usulan: sekurang-kurangnya 80% soal RAG sesuai, dan lebih tinggi daripada soal tanpa RAG.
2	Kualitas retrieval dan sitasi.	Pada 20 kueri topik, precision@5 sekurang-kurangnya 80% (pembanding: 85% pada Paper 1), dan 100% soal RAG memuat sitasi (dokumen dan halaman/pasal) yang dapat dibuka dan relevan menurut reviewer.
3	Alur end-to-end dan penerimaan petugas.	Alur unggah dokumen, generate, review, Bank Soal, hingga sesi ujian berjalan tanpa galat pada 10 sesi simulasi (100% sesi berisi soal unik dengan kunci valid). Minimal 3 petugas Checkpoint/Safety atau pembimbing menyelesaikan alur tanpa bantuan dengan skor SUS sekurang-kurangnya 68; waktu generate 20 soal dicatat (target usulan: tidak lebih dari 10 menit).

J Keputusan Akhir Kelompok

Ide yang dipilih

Pengembangan Sistem Generator Soal Ujian Teori Berkendaraan Otomatis Berbasis Large Language Model dan Retrieval-Augmented Generation (RAG) dari Dokumen Peraturan Keselamatan.

Alasan memilih ide

Melanjutkan sistem IMKP yang sudah dikerjakan saat KP, sehingga alur, data, dan teknologi dasar (Ollama, Bank Soal, riwayat soal AI, plan ujian) sudah ada dan demo realistis.

Masalahnya jelas dan terhubung ke tujuan keselamatan: soal harus selaras dengan peraturan, bukan hanya variatif. RAG menjawab hal itu dan belum ada pada sistem KP.

Kontribusi capstone terpisah dan terukur (RAG, sitasi, pemeriksaan otomatis, evaluasi terhadap pembanding tanpa RAG), serta didukung tiga paper yang saling melengkapi.

Asumsi yang masih perlu diverifikasi

1) Dokumen peraturan keselamatan RU II tersedia dan boleh dipakai untuk capstone; bila tidak, korpus publik/buatan dipakai.

2) Kualitas model lokal (qwen2.5:7b atau lainnya) cukup untuk bahasa Indonesia dan perangkat demo mampu menjalankannya.

3) Peran pengguna: pada laporan KP lima peran adalah MasterAdmin, Vendor, Checkpoint, PengawasSafety, dan Peserta, sedangkan pada canvas ini lima entitas adalah Vendor, Refinery Unit, Checkpoint, Petugas Safety, dan Peserta (Refinery Unit sebagai lingkup data). Perlu diselaraskan dengan dosen.

4) Sistem hanya menguji pemahaman teori; kemampuan mengemudi sebenarnya memerlukan uji praktik di luar scope.

5) Detail ketiga paper (angka, bagian, tabel) perlu dibuka ulang kelompok pada sumber aslinya. Nama kelompok dan anggota lain belum diisi.

Pertanyaan untuk dosen atau reviewer

1) Generator AI berbasis kategori topik sudah dibuat pada masa KP. Apakah RAG dari dokumen, sitasi, pemeriksaan otomatis, dan evaluasi pembanding sudah cukup sebagai kontribusi baru capstone?

2) Siapa yang berwenang memvalidasi kebenaran isi soal terhadap peraturan (Checkpoint atau Petugas Safety), dan berapa banyak reviewer yang memadai untuk evaluasi?

3) Apakah penjelasan batas scope (hanya ujian teori, tanpa uji praktik) sudah dapat diterima terhadap tujuan memastikan pengemudi kilang benar-benar mampu mengemudi?

Status setelah review

- ☐ Layak dilanjutkan
- ☐ Layak dengan revisi
- ☐ Perlu mengganti atau mempersempit ide

Panduan Presentasi Tiga Menit

1. Masalah dan target pengguna • 2. Bukti dari tiga paper • **3. Gap yang dipilih** • **4. Solusi dan demo minimum** • 5. Risiko atau hal yang masih perlu divalidasi

Rubrik Review Cepat

Aspek	Pertanyaan pemeriksaan	Skor 1 sampai 4	Catatan
Bukti	Apakah gap didukung oleh beberapa paper?		

Aspek	Pertanyaan pemeriksaan	Skor 1 sampai 4	Catatan
Masalah	Apakah masalah dan target pengguna jelas?		
Relevansi	Apakah solusi menjawab masalah yang dinyatakan?		
Kelayakan	Apakah demo realistis dibuat selama capstone?		
Kontribusi	Apakah pembeda dari penelitian sebelumnya jelas?		
Pengukuran	Apakah keberhasilan proyek dapat diuji?		

Keputusan reviewer: ☐ Disetujui ☐ Revisi ringan ☐ Revisi substansial